



UNIVERSIDAD TÉCNOLOGICA NACIONAL
FACULTAD REGIONAL GENERAL PACHECO

TECNICATURA UNIVERSITARIA EN PROGRAMACIÓN

Base de Datos II

Conceptos de Big Data

ING. ARIEL HERRERA



Contenido

Conceptos generales	2
El Teorema CAP.....	2
1. Sistemas CP (Consistencia + Tolerancia a Particiones)	3
Ejemplo: Un Sistema Bancario	4
2. Sistemas AP (Disponibilidad + Tolerancia a Particiones)	4
Ejemplo: Un Feed de Red Social.....	4
Conclusión.....	5



Conceptos generales

El **Big Data** (o datos masivos) se refiere a **conjuntos de datos extremadamente grandes y complejos** que los métodos tradicionales de procesamiento no pueden manejar.

Se define por las **5 V** principales:

- **Volumen:** La inmensa cantidad de datos generados.
- **Velocidad:** La rapidez con la que se generan, recopilan y procesan los datos (a menudo en tiempo real).
- **Variedad:** La diversidad de formatos y fuentes de los datos (estructurados, no estructurados como videos, textos, etc.).
- **Veracidad:** La necesidad de asegurar la calidad y fiabilidad de los datos.
- **Valor:** El potencial para extraer información significativa y útil para la toma de decisiones.

Las organizaciones utilizan el Big Data, con ayuda de tecnologías como la **Inteligencia Artificial** (IA) y el **aprendizaje automático** (*Machine Learning*), para encontrar **patrones**, obtener **conocimiento profundo** (*insights*) y tomar **decisiones estratégicas** más informadas, mejorando la eficiencia, personalizando servicios y ganando competitividad. Se utiliza para obtener valor en:

- **Comercio minorista (Retail):** Personalización de ofertas y optimización de inventario.
- **Finanzas:** Detección de fraude, gestión de riesgos y análisis de mercado.
- **Salud:** Medicina personalizada, predicción de epidemias y optimización de tratamientos.
- **Marketing:** Segmentación precisa de clientes y predicción de comportamiento.
- **Logística:** Optimización de rutas y cadena de suministro.

El Teorema CAP

El **Teorema CAP** (o Teorema de Brewer) es un principio fundamental en el diseño de **sistemas distribuidos** (como los usados en Big Data) que establece que es **imposible garantizar simultáneamente** las tres propiedades siguientes:

1. **Consistencia (C):** Todos los nodos ven los **mismos datos** al mismo tiempo.



2. **Disponibilidad (A):** Cada solicitud recibe una **respuesta** (sin error) en un tiempo razonable, incluso si no es el dato más reciente.
3. **Tolerancia a Particiones (P):** El sistema **continúa funcionando** a pesar de fallos de comunicación entre los nodos de la red.
4. En la práctica, debido a que las particiones de red son inevitables en un sistema distribuido (la **P** siempre debe priorizarse), los diseñadores de bases de datos deben elegir entre **Consistencia (C) o Disponibilidad (A)**:

Enfoque	Propiedades Priorizadas	Se sacrifica	Ejemplo de uso
CP	Consistencia y Tolerancia a Particiones	Disponibilidad	Sistemas bancarios (la precisión del saldo es crítica). Bases de datos como MongoDB o HBase .
AP	Disponibilidad y Tolerancia a Particiones	Consistencia	Redes sociales o e-commerce (la velocidad de respuesta es crítica). Bases de datos como Cassandra o CouchDB .

El teorema CAP es crucial para entender por qué las diferentes bases de datos NoSQL (usadas en Big Data) están optimizadas para distintos escenarios.

Un ejemplo práctico ayuda a entender perfectamente el dilema del Teorema CAP.

Imaginemos un sistema distribuido que tiene dos nodos (A y B) con una copia de los datos. De repente, ocurre una **partición de red (P)**, lo que significa que los nodos A y B no pueden comunicarse entre sí.

El sistema debe elegir cómo responder a las solicitudes de los usuarios mientras dura esta partición:

1. Sistemas CP (Consistencia + Tolerancia a Particiones)

Estos sistemas **sacrifican la Disponibilidad (A)** para asegurar que los datos sean siempre **Consistentes (C)**.

Propiedades	Detalle
C (Consistencia)	Priorizada
P (Tolerancia a Particiones)	Priorizada
A (Disponibilidad)	Sacrificada



Ejemplo: Un Sistema Bancario

Imagina que un cliente tiene \$1000 en su cuenta (el dato está en el Nodo A y en el Nodo B).

1. El cliente intenta hacer un retiro de \$500.
2. La solicitud de retiro llega al **Nodo A** y lo actualiza a \$500.
3. Debido a la partición de red (P), el Nodo A **no puede notificar al Nodo B**.
4. Para garantizar la Consistencia (C) —que el saldo sea siempre correcto—, el Nodo A **bloquea la operación** en el Nodo B y se niega a responder a cualquier otra solicitud de lectura o escritura en el Nodo B hasta que se restablezca la comunicación y los datos puedan sincronizarse.
5. **Resultado:** El sistema bancario es **temporalmente no disponible** para el cliente que intenta acceder al Nodo B, pero se **garantiza que el saldo nunca será incorrecto**. La precisión es más importante que la respuesta inmediata.

2. Sistemas AP (Disponibilidad + Tolerancia a Particiones)

Estos sistemas **sacrifican la Consistencia (C)** (temporalmente) para asegurar la **Disponibilidad (A)**.

Propiedades	Detalle
A (Disponibilidad)	Priorizada
P (Tolerancia a Particiones)	Priorizada
C (Consistencia)	Sacrificada (se usa Consistencia Eventual)

Ejemplo: Un Feed de Red Social

Imagina que un usuario publica un comentario en una red social.

1. El comentario se guarda inmediatamente en el **Nodo A**.
2. Debido a la partición de red (P), el Nodo A **no puede notificar al Nodo B**.
3. Para garantizar la Disponibilidad (A) —que la *app* siga funcionando—, el Nodo B **sigue respondiendo** a las peticiones con los datos que tiene.



4. Resultado:

- Un usuario que se conecta al **Nodo A verá inmediatamente** el nuevo comentario (el dato más reciente).
 - Un usuario que se conecta al **Nodo B no verá el comentario** inmediatamente (el dato es temporalmente inconsistente/obsoleto), pero **la aplicación sigue funcionando** y respondiendo sin errores.
5. La red social prioriza la experiencia ininterrumpida del usuario sobre la consistencia perfecta. El comentario aparecerá en el Nodo B tan pronto como se solucione la partición (esto se llama **Consistencia Eventual**).

Conclusión

La elección entre CP y AP depende enteramente de la necesidad de tu negocio:

- **¿Es más importante que el dato sea 100% correcto (ej. dinero, inventario)?** → Elige un sistema **CP** (Consistencia).
- **¿Es más importante que el servicio nunca se caiga y dé una respuesta rápida (ej. publicaciones, me gusta)?** → Elige un sistema **AP** (Disponibilidad).